Propuesta de Datos · Proyecto Centinela · Fase 1

Oct 29, 2026 · @Sergio Cardozo

0. Encabezado

Campo	Detalle
Título del proyecto	Centinela del Dengue: alerta temprana de brotes por municipio en Colombia
Integrantes	Sergio Alexander Cardozo Ovadia · Cesar Augusto Coy Velandia (equipo de 2)
Fecha	2026-10-29
Versión	v1 (Fase 1)

1. Problema, cliente y objetivo binario

- **Evento de riesgo y cliente:** el sistema anticipa, con una semana de ventaja, si un municipio entrará en brote de dengue; el cliente son los programas de Enfermedades Transmitidas por Vectores (ETV) de las secretarías de salud de 10 municipios endémicos: Barranquilla, Bucaramanga, Cali, Cúcuta, Ibagué, Itagüí, Medellín, Montería, Neiva y Villavicencio.
- **Impacto:** una semana de anticipación permite intensificar la eliminación de criaderos y el control focal del vector, y preparar la red de urgencias antes de que crezcan los casos graves.
- **Objetivo binario:** `brote = 1` si la incidencia semanal de dengue (casos por 100.000 habitantes) del municipio en la semana epidemiológica $t + 1$ supera el límite superior de su canal endémico, calculado por el método de cuartiles (tercer cuartil, Q3) con la misma semana de los 5 años previos; si no, `brote = 0`. El modelo solo usa información disponible hasta la semana t.
- **Justificación del umbral:** el canal endémico es la herramienta con la que la vigilancia en salud pública en Colombia declara la zona de brote, así que la alerta habla el mismo idioma del cliente. Se pierde la magnitud del brote (cuántos casos por encima del

umbral) y la distinción entre zonas de éxito, seguridad y alerta. Como no avisar un brote cuesta más que una falsa alarma, el *recall* de la clase brote es la métrica prioritaria.

2. Las dos modalidades del sistema completo

- **Rama de imagen:** cada imagen es una escena Sentinel-2 del área urbana de un municipio en una semana epidemiológica (2016–2018), con 12 bandas espectrales llevadas a 10 m. La produce el instrumento multiespectral MSI de los satélites Sentinel-2 (ESA/Copernicus). Aporta la textura urbana, la vegetación, los cuerpos de agua y la nubosidad, rasgos asociados a la disponibilidad de criaderos de *Aedes aegypti*.
- **Rama temporal:** casos semanales de dengue por municipio (notificación obligatoria al SIVIGILA, Instituto Nacional de Salud) desde 2007, con su población (proyecciones DANE) y variables climáticas diarias de NASA POWER agregadas por semana: temperatura media, máxima y mínima, humedad relativa y precipitación.
- **Pregunta de control, «¿La imagen contiene algo que un número no contenga?»:** sí. La imagen registra la distribución espacial de la cobertura urbana, la vegetación y el agua del municipio esa semana, algo que ningún conteo de casos ni serie de clima puntual contiene. Son dos instrumentos físicamente independientes: un radiómetro satelital y un sistema de notificación clínica; ninguna se deriva de la otra.

3. Fuentes (con enlaces y licencia)

Modalidad	Fuente (productor primario)	Enlace o DOI	Licencia y versión	Dónde se verificó la licencia	¿Datos de personas?
Imagen	Sentinel-2 (ESA/Copernicus), curado por Cajas et al. (2024) en PhysioNet, subconjunto `10_municipalities`	doi.org/10.13026/xr5s-xe24	CC0 1.0 Universal	Ficha de PhysioNet v1.0.0 (sección Files y LICENSE.txt)	No: territorio a 10 m por píxel, sin personas identificables

Modalidad	Fuente (productor primario)	Enlace o DOI	Licencia y versión	Dónde se verificó la licencia	¿Datos de personas?
Temporal	SIVIGILA, Instituto Nacional de Salud: microdatos del evento dengue, 2007–2025, descargados con el paquete de R sivirep 1.0.2	portalsivigila.ins.gov.co · sivirep	Datos abiertos del Estado (Ley 1712 de 2014, art. 6 lit. j); no publica licencia CC	Página de Datos Abiertos del INS	Sí: datos de salud anonimizados por la fuente; se usan solo agregados por municipio y semana
Temporal	NASA POWER (NASA Langley Research Center), API diaria por coordenadas	power.larc.nasa.gov	Datos NASA de libre uso, con cita	Página de la fuente y catálogo de fuentes del curso	No
Temporal (denominador)	DANE: proyecciones de población municipal, vía sivirep	dane.gov.co	Datos abiertos del Estado (Ley 1712 de 2014)	Portal del DANE	No: totales municipales

4. Por qué NO es un reto resuelto

- **Dato crudo:** SIVIGILA entrega una fila por caso notificado, no una tabla lista. Hay que filtrar el evento, ubicar el municipio de procedencia (donde probablemente ocurrió el contagio), contar por semana epidemiológica, calcular la incidencia con la población DANE y construir la etiqueta con el canal endémico. Los casos de las últimas semanas se ajustan después por notificación tardía, la etiqueta queda desbalanceada y las escalas de casos, población y clima son heterogéneas: todo exige EDA. En la rama de imagen, parte de las escenas viene negra o cubierta de nubes (archivos de unos 9,5 KB frente a 1–4 MB).
- **Sin réplica de Kaggle:** la búsqueda en kaggle.com del 2026-10-30 encontró dos conjuntos relacionados, declarados y contrastados en el anexo B. Ninguno coincide con nuestros archivos: no contienen las imágenes Sentinel-2 crudas ni la serie 2007–2025 construida desde los microdatos, y este proyecto no descarga nada de Kaggle.
- **Sin solución pública que copiar:** el trabajo publicado con estas imágenes, DengueNet (Kuo et al., 2024), hace regresión del número de casos en 5 municipios con solo imágenes de 2016–2018. Nuestra formulación es distinta: clasificación binaria de brote

a una semana según el canal endémico, 10 municipios, serie de 2007 a 2025 con clima, primero con un MLP tabular y después con fusión multimodal. El reto más cercano, el datatón Make Health LATAM 2022 (anexo B), usó tablas hasta 2019 y rasgos precalculados de imágenes solo para Medellín; no conocemos una competencia ni un código público con nuestro planteamiento.

5. Plan de la Fase 1, clave de alineación y prueba de acoplamiento

- **Modalidad que se modela en la Fase 1 (aplanada a tabla):** la serie temporal. Cada fila es un par (municipio, semana *t*) con rezagos de la incidencia (*t* a *t − 4*), medias móviles, rezagos climáticos de 1 a 4 semanas (el ciclo del vector responde con retraso a lluvia y temperatura) y la estacionalidad codificada con seno y coseno de la semana. La etiqueta es el brote en *t + 1*.
- **Paso a la Fase 2:** la serie pasa a su arquitectura nativa (LSTM y GRU sobre ventanas de varias semanas) y entra la imagen con una CNN preentrenada (aprendizaje por transferencia); ambas se fusionan para emitir la alerta.
- **Clave de alineación:**
  - [ ] Agregada
  - [x] ~~**Por muestra:** (código DIVIPOLA del municipio, semana epidemiológica). En PhysioNet cada carpeta es un código DIVIPOLA (p. ej., `8001` = Barranquilla) y cada archivo se nombra con el primer día de la semana epidemiológica (`image_2016-01-03.tiff` = semana 1 de 2016). En SIVIGILA cada caso trae municipio, año y semana epidemiológica. **Salvedad:** las imágenes solo cubren 2016–2018, así que la fusión de la Fase 2 se limita a esa ventana (10 municipios × ~156 semanas ≈ 1.560 muestras); las escenas negras o nubladas se marcan y no se emparejan.~~
- **Prueba de acoplamiento:** diez filas reales en el anexo A.
- **Partición cronológica:** la etiqueta existe desde 2012 (el canal usa 2007–2011 como primeros 5 años). Entrenamiento 2012–2019, validación 2020–2022 y prueba 2023–2025. Rezagos, canal endémico y escalador se calculan sin mirar el futuro: el escalador se ajusta solo con entrenamiento. Para que la Fase 2 tenga contra qué compararse, la Fase 1 reporta además el MLP en la ventana común 2016–2018 (entrenamiento 2016–2017, prueba 2018).

6. Línea base comprometida

El MLP debe superar en el conjunto de prueba estas dos referencias, que se conservan con la misma partición y semilla para la Fase 2.

Referencia	Qué se reporta en prueba
Clase mayoritaria («no brote»)	Exactitud y *recall* de la clase brote, que vale 0
Escalar crudo: persistencia, «el municipio ya está por encima de su canal en la semana *t*»	Umbral elegido en validación; exactitud, precisión, *recall* y F1 de la clase brote

La persistencia es la regla que hoy aplica una secretaría con el canal endémico: si el MLP no la supera, no aporta valor al cliente.

7. Riesgos éticos y protección de datos

Riesgo	Daño para el cliente	Mitigación
Sesgo de muestreo o representatividad: 10 municipios urbanos grandes; subregistro desigual según acceso a salud; vigilancia alterada en 2020–2021 por COVID-19	El modelo no sirve para municipios rurales o pequeños, y puede aprender el subregistro como si fuera «menos dengue»	Se declara el alcance (solo estos 10 municipios); métricas por municipio; 2020–2021 se analiza aparte en el EDA
Falsa alarma	Gasto en fumigación y brigadas sin necesidad, presión de resistencia del vector a insecticidas y fatiga de alertas en el equipo	Umbral de decisión escogido con el costo de cada error; se reporta la precisión junto al *recall*; la alerta orienta una verificación en campo, no una fumigación automática
Alarma omitida	Un brote avanza sin intervención: más hospitalizaciones, casos de dengue grave y muertes evitables	Se prioriza el *recall* de la clase brote; el sistema complementa el canal endémico oficial y nunca lo reemplaza
Notificación tardía: los casos recientes se ajustan semanas después	En producción el modelo vería menos casos de los reales y subestimaría el riesgo	Se documenta en el informe y se deja como limitación para la Fase 3

Riesgo	Daño para el cliente	Mitigación
Datos de salud (Ley 1581 de 2012, art. 5)	Riesgo de reidentificación en semanas con pocos casos	Solo agregados municipio-semana; no se cruzan con fuentes que permitan reidentificar; a la IA solo se le muestra el esquema; checklist completo en el anexo C

8. Cita APA 7 de cada fuente

- Cajas, S. A., Restrepo, D., Moukheiber, D., Kuo, K. T., Wu, C., Garcia Chicangana, D. S., Paddo, A. R., Moukheiber, M., Moukheiber, L., Moukheiber, S., Purkayastha, S., Lopez, D. M., Kuo, P.-C., & Celi, L. A. (2024). *A multi-modal satellite imagery dataset for public health analysis in Colombia* (versión 1.0.0) [Conjunto de datos]. PhysioNet. https://doi.org/10.13026/xr5s-xe24
- Instituto Nacional de Salud. (2026). *Sistema Nacional de Vigilancia en Salud Pública (SIVIGILA): microdatos del evento dengue, 2007–2025* [Conjunto de datos]. https://portalsivigila.ins.gov.co/
- Gómez-Millán, G., Cucunubá, Z. M., Mendez-Romero, J. A., & Huguett-Aragón, C. (2025). *sivirep* (versión 1.0.2) [Paquete de R]. Pontificia Universidad Javeriana. https://epiverse-trace.r-universe.dev/sivirep
- NASA Langley Research Center. (s.f.). *NASA Prediction of Worldwide Energy Resources (POWER)* [Conjunto de datos]. https://power.larc.nasa.gov/
- Departamento Administrativo Nacional de Estadística. (s.f.). *Proyecciones y retroproyecciones de población municipal* [Conjunto de datos]. https://www.dane.gov.co/
- Kuo, K.-T., Moukheiber, D., Cajas Ordonez, S., Restrepo, D., Paddo, A. R., Chen, T.-Y., Moukheiber, L., Moukheiber, M., Moukheiber, S., Purkayastha, S., Kuo, P.-C., & Celi, L. A. (2024). *DengueNet: Dengue prediction using spatiotemporal satellite imagery for resource-limited countries* (arXiv:2401.11114). arXiv. https://arxiv.org/abs/2401.11114

Anexo A · Prueba de acoplamiento

Clave: (DIVIPOLA `08001` Barranquilla, semana epidemiológica de 2016). Los nombres de archivo son los publicados en PhysioNet; los casos (eventos 210 y 220, municipio de procedencia) salen del código de abajo, ejecutado el 2026-10-30.

N.º	Clave	Dato de la rama de imagen (archivo)	Dato de la serie: casos de dengue en la semana
1	(08001, 2016-SE01)	`10_municipalities/images/8001/image_2016-01-03.tiff`	*52*
2	(08001, 2016-SE02)	`image_2016-01-10.tiff`	*54*
3	(08001, 2016-SE03)	`image_2016-01-17.tiff`	*50*
4	(08001, 2016-SE04)	`image_2016-01-24.tiff`	*26*
5	(08001, 2016-SE05)	`image_2016-01-31.tiff`	*32*
6	(08001, 2016-SE06)	`image_2016-02-07.tiff`	*29*
7	(08001, 2016-SE07)	`image_2016-02-14.tiff`	*16*
8	(08001, 2016-SE08)	`image_2016-02-21.tiff`	*9*
9	(08001, 2016-SE09)	`image_2016-02-28.tiff`	*13*
10	(08001, 2016-SE10)	`image_2016-03-06.tiff`	*8*

Código que produce las diez filas (R):

```
library(sivirep)
library(dplyr)

dir.create("tmp_xls", showWarnings = FALSE)
dengue_2016 <- import_data_event(nombre_event = "dengue", years = 2016,
                                 ruta_dir = "tmp_xls", cache = FALSE)

filas_acople <- dengue_2016 |>
  filter(cod_eve %in% c("210", "220"), as.integer(cod_dpto_o) == 8,
as.integer(cod_mun_o) == 1, as.integer(semana) <= 10) |>
  count(semana, name = "casos") |>
  mutate(
    clave   = sprintf("(08001, 2016-SE%02d)", semana),
    archivo = sprintf("image_%s.tiff",
                      format(as.Date("2016-01-03") + 7 * (semana - 1), "%Y-
%m-%d"))
  )
filas_acople
```

Anexo B · Evidencias del test de procedencia

1. **Cadena de procedencia:**

Archivo (nombre exacto)	URL o DOI del productor primario	Fecha de descarga	Huella SHA-256
`dengue_10mun_semana.csv` (9.920 × 5, agregado desde los microdatos; queda fuera del repositorio público)	portalsivigila.ins.gov.co vía sivirep	*2026-10-30*	*ac5d96f77ce4f93f8c5d9a716a5cb360ed662c09d6363c5f23cd4e48f5f5ea22*
`nasa_power_10_municipios.csv`	power.larc.nasa.gov (API diaria)	*(AAAA-MM-DD)*	*(se calcula en el cuaderno)*
`10_municipalities/images/8001/image_2016-01-03.tiff`	doi.org/10.13026/xr5s-xe24	*(AAAA-MM-DD)*	*(se calcula en el cuaderno)*

2. **Descarga trazable:** el script de R descarga SIVIGILA con `sivirep::import_data_event()`; la celda de clima llama a la API de NASA POWER por coordenadas. El cuaderno no usa `kaggle`, `kagglehub` ni `/kaggle/input`; se verifica con `grep -inE "kaggle|kagglehub|/kaggle/input" *.ipynb` → *(resultado)*.
3. **Búsqueda declarada de espejos** (2026-10-30, en kaggle.com con «SIVIGILA dengue» y «satellite imagery public health Colombia»): dos coincidencias. (1) Dengue Tabular Data and Satellite Images, de David Restrepo, coautor del conjunto de PhysioNet: material del datatón Make Health LATAM 2022, 9,74 MB, licencia «Unknown». (2) Dengue & Climate Data Colombia (2010–2024), de Juan Torr: conteos semanales de 376 municipios con clima, 34 MB, CC BY-NC-SA 4.0.

4. **Huella de crudeza** (antes de limpiar): *1.757.820 casos × 68 columnas (2007–2025, todo el país); 0 % de vacíos en las 6 columnas usadas; eventos 210 = 1.705.604, 220 = 50.101 y 580 = 2.115 (el 580, mortalidad, se excluye para no contar dos veces); ajuste 0 = 1.133.267, 3 = 460.132, 5 = 69.566 y 7 = 94.855 (el INS no publica descartados 6 ni D). Tras agregar: 9.920 filas (10 municipios × 992 semanas; 2008, 2014, 2020 y 2025 tienen semana 53). Escalas muy distintas: media semanal de 8,5 casos en Itagüí frente a 165 en Cali, y 77 % de las semanas de Itagüí con menos de 5 casos. El balance de la etiqueta se reporta en el cuaderno, al construir el canal endémico*.
5. **Contraste con el espejo:** ninguno de los dos coincide con nuestros archivos. (1) El conjunto del datatón trae tablas de casos de 2007 a 2019 y, para la imagen, solo rasgos precalculados de Medellín (`features_resnet50.csv` , embeddings y PCA); no contiene escenas Sentinel-2. Nosotros usamos las escenas crudas de 12 bandas de 10 municipios de la versión 1.0.0 de PhysioNet (2024, DOI propio) y no usamos ninguno de sus rasgos. (2) El conjunto de Juan Torr cubre 2010–2024 con un código de municipio de notificación; nuestra serie se construye desde los microdatos del INS, cubre 2007–2025, cuenta por municipio de procedencia (eventos 210 y 220) y tiene huella SHA-256 propia (`ac5d96f7…`).

Anexo C · Checklist de protección de datos personales (Ley 1581 de 2012)

Fuente: SIVIGILA (INS), microdatos del evento dengue

Resultado: datos de personas anonimizados por la fuente.

- [x] ~~**A.** Se revisaron las columnas: no traen nombre, documento, dirección ni teléfono. Edad, sexo, fecha y municipio son identificadores indirectos y no se conservan a nivel de caso.~~
- [x] ~~**B.** Son datos de salud (art. 5). Se usa la finalidad estadística con supresión de identidad (art. 6 lit. e) sobre datos anonimizados por la fuente oficial, y no se cruzan con fuentes que permitan reidentificar.~~
- [x] ~~**C.** Puede haber menores entre los casos: por eso solo se usan conteos agregados de fuente oficial.~~
- [x] ~~**D.** Fuente pública oficial (Ley 1712 de 2014); se cita en la sección 8.~~
- [x] ~~**E.** Finalidad: «uso académico para entrenar y evaluar un modelo en el curso; no se toman decisiones sobre personas identificadas».~~
- [x] ~~**F.** Se agrega a municipio y semana inmediatamente después de la descarga. Prueba de reidentificación: con 10 municipios de más de 250.000 habitantes y solo conteos semanales, no es posible señalar a una persona; aun así, ninguna salida publicada muestra celdas con menos de 5 casos sin agregar.~~

- [x] ~~**G.** Datos abiertos del Estado; se cumple la cita obligatoria.~~
- [x] ~~**H.** A Colab y GitHub solo sube la tabla agregada. A los asistentes de IA solo se les muestra el esquema (nombres y tipos de columnas) o filas sintéticas.~~
- [x] ~~**I.** Solo se conservan las columnas de evento, año, semana y municipio. Los microdatos quedan en el equipo local y se borran al terminar el curso.~~
- [x] ~~**J.** Repositorio público en GitHub (lo pide el docente) sin datos de casos: trae el script de descarga desde la fuente primaria y los microdatos y tablas derivadas van en `.gitignore`.~~

Fuentes sin datos de personas: PhysioNet (Sentinel-2), NASA POWER y DANE

Resultado: sin datos de personas.

Bloque	PhysioNet (Sentinel-2)	NASA POWER	DANE
A–C. Personas, datos sensibles, menores	No: píxeles de 10 m, sin rostros ni placas	No: variables climáticas	No: totales municipales
D. Base legal	Licencia CC0 1.0	Uso libre con cita	Datos abiertos (Ley 1712)
G. Licencia verificada	Ficha PhysioNet v1.0.0	Página de la fuente	Portal del DANE
H–J. Nube y repositorio	Sin restricción; el repositorio trae el script de descarga	Igual	Igual

Declaración. Lo consignado en este checklist es verdadero y se revisó para cada fuente de la Propuesta.

Integrante	Firma	Fecha
Sergio Alexander Cardozo Ovadia	Cardozo S.	30/10/2026
Cesar Augusto Coy Velandia	Cesar Coy	30/10/2026